LAPORAN PROYEK NATURAL LANGUAGE PROCESSING

Analisis Sentimen Ulasan Instagram Menggunakan Bag-of-Words dan TF-IDF

Disusun oleh:

Pasek Nyoman Agus Mahendra Jaya (2301020091)

Dosen Pengampu :

Ida Bagus Kresna Sudiatmika, S.Kom., M.T.,

PROGRAM STUDI TEKNIK INFORMATIKA

FAKULTAS TEKNOLOGI INFORMASI DAN DESAIN

UNIVERSITAS PRIMAKARA

2026

Abstrak

Proyek ini membahas pembangunan sistem analisis sentimen sederhana berbasis Python untuk data ulasan Instagram berbahasa Indonesia. Dataset yang digunakan berisi 1.000 dokumen dan memiliki lima kelas label sentimen. Alur kerja penelitian dimulai dari preprocessing teks, meliputi cleaning, case folding, tokenization, stopword removal, dan stemming dengan Sastrawi. Setelah itu, teks direpresentasikan menggunakan dua metode klasik, yaitu Bag-of-Words dan TF-IDF, lalu diklasifikasikan menggunakan Logistic Regression. Hasil pengujian pada notebook menunjukkan akurasi 51% untuk Bag-of-Words dan 52% untuk TF-IDF. Meskipun selisihnya kecil, TF-IDF memberikan performa yang sedikit lebih baik karena mampu memberi bobot lebih pada kata yang lebih informatif. Dari analisis ini dapat disimpulkan bahwa preprocessing yang baik dan pemilihan representasi teks sangat berpengaruh terhadap kualitas model, terutama pada data bahasa Indonesia yang cenderung memiliki variasi bentuk kata yang cukup tinggi.

Daftar Isi

Daftar Isi 3
1. Pendahuluan 4
1.1 Rumusan Masalah 4
1.2 Tujuan Penelitian 4
1.3 Ruang Lingkup 4
2. Tinjauan Pustaka 5
2.1 Preprocessing Teks 5
2.2 Bag-of-Words 5
2.3 TF-IDF 5
2.4 Logistic Regression 5
3. Metodologi Penelitian 6
3.1 Dataset 6
3.2 Tahapan Preprocessing 6
3.3 Representasi Teks 6
3.4 Split Data dan Pemodelan 7
4. Hasil dan Pembahasan 7
4.1 Distribusi Data 7
4.2 Contoh Hasil Preprocessing 7
4.3 Perbandingan Representasi Teks 8
4.4 Analisis Performa Model 8
4.5 Kelebihan dan Keterbatasan 9
5. Kesimpulan dan Saran 9
5.1 Kesimpulan 9
5.2 Saran 9
Daftar Pustaka 10

1. Pendahuluan

Natural Language Processing (NLP) merupakan bidang yang berfokus pada kemampuan komputer untuk memahami, menganalisis, dan menghasilkan bahasa manusia. Di era media sosial, jumlah teks yang muncul setiap hari sangat besar, mulai dari komentar, ulasan produk, pesan singkat, hingga diskusi publik mengenai suatu layanan. Kondisi ini membuat NLP menjadi alat yang penting karena proses analisis manual sudah tidak lagi efisien untuk skala data yang besar.

Dalam konteks media sosial, analisis sentimen digunakan untuk mengetahui kecenderungan opini pengguna terhadap suatu produk, aplikasi, atau layanan. Sentimen tidak hanya membantu mengetahui apakah suatu tanggapan bersifat positif atau negatif, tetapi juga memberi gambaran tentang masalah yang paling sering dirasakan oleh pengguna. Informasi seperti ini sangat berguna untuk pengembangan produk dan pengambilan keputusan.

Proyek ini mengambil data ulasan Instagram sebagai objek analisis. Pemilihan data Instagram cukup relevan karena platform tersebut memiliki jumlah interaksi yang tinggi dan banyak memuat opini spontan dari pengguna. Tantangan utamanya adalah bahasa yang digunakan sering tidak baku, penuh singkatan, emoji, dan typo. Oleh sebab itu, tahapan preprocessing menjadi bagian penting sebelum data dimasukkan ke model.

1.1 Rumusan Masalah

- Bagaimana cara membersihkan teks berbahasa Indonesia agar dapat diolah oleh model NLP?
- Metode representasi teks mana yang lebih baik antara Bag-of-Words dan TF-IDF pada dataset ini?
- Seberapa besar perbedaan performa model setelah proses preprocessing dan vectorization dilakukan?

1.2 Tujuan Penelitian

- Membangun alur kerja NLP sederhana berbasis Python yang dapat dijalankan ulang.
- Menerapkan preprocessing teks secara lengkap pada data ulasan Instagram.
- Membandingkan dua metode representasi teks klasik pada tugas klasifikasi sentimen.
- Menyusun laporan yang mudah dibaca, rapi, dan tetap dapat diedit oleh pengguna.

1.3 Ruang Lingkup

Pembahasan difokuskan pada pendekatan machine learning dasar tanpa menggunakan model transformer besar seperti BERT atau GPT. Model yang dipakai adalah Logistic Regression karena sederhana, cepat, dan cukup umum digunakan sebagai baseline dalam

klasifikasi teks. Kelas label pada dataset mengikuti label yang tersedia pada data mentah, yaitu lima kelas sentimen, sehingga proyek ini diperlakukan sebagai klasifikasi multi-kelas.

2. Tinjauan Pustaka

NLP memiliki banyak tahapan sebelum sebuah model dapat bekerja dengan baik. Secara umum, teks mentah harus diubah menjadi bentuk yang lebih bersih, lebih konsisten, dan dapat direpresentasikan secara numerik. Dalam proyek ini digunakan beberapa konsep dasar yang menjadi fondasi penting dalam pemrosesan bahasa.

2.1 Preprocessing Teks

Preprocessing bertujuan mengurangi noise pada data. Cleaning digunakan untuk menghapus karakter yang tidak diperlukan, seperti tanda baca berlebih, angka, dan simbol. Case folding membuat seluruh teks menjadi huruf kecil agar kata yang sama tidak dianggap berbeda. Tokenization memecah kalimat menjadi token-token kecil, sedangkan stopword removal menghapus kata umum yang kurang informatif. Stemming kemudian mengubah kata berimbuhan menjadi bentuk dasarnya. Untuk Bahasa Indonesia, Sastrawi menjadi pilihan yang praktis dan cukup efektif.

2.2 Bag-of-Words

Bag-of-Words merepresentasikan teks berdasarkan jumlah kemunculan kata. Setiap dokumen diubah menjadi vektor yang berisi frekuensi kata dari seluruh kosakata. Metode ini mudah dipahami dan sering dipakai sebagai baseline. Kekurangannya, urutan kata tidak diperhatikan sehingga informasi konteks bisa hilang.

2.3 TF-IDF

TF-IDF adalah representasi teks yang menekankan kata penting dalam suatu dokumen dengan mempertimbangkan seberapa sering kata tersebut muncul di seluruh korpus. Kata yang sering muncul di banyak dokumen akan memperoleh bobot lebih kecil, sedangkan kata yang spesifik terhadap topik tertentu akan diberi bobot lebih besar. Secara praktis, TF-IDF sering memberi hasil lebih baik daripada frekuensi murni karena dapat menekan pengaruh kata umum.

2.4 Logistic Regression

Logistic Regression merupakan algoritma klasifikasi yang populer untuk teks karena sederhana namun cukup kuat untuk baseline. Model ini mempelajari hubungan antara fitur numerik hasil vectorization dan label sentimen. Pada kasus multi-kelas, model akan memprediksi kelas dengan probabilitas tertinggi.

3. Metodologi Penelitian

Penelitian ini menggunakan alur kerja yang terdiri dari empat tahap utama, yaitu pengumpulan data, preprocessing teks, ekstraksi fitur, dan pemodelan. Seluruh proses dilakukan di Python dengan notebook Jupyter sehingga setiap langkah dapat dijalankan ulang dengan mudah.

3.1 Dataset

Dataset yang digunakan berisi 1.000 ulasan Instagram. Dari hasil pemuatan data pada notebook, terlihat bahwa distribusi label tidak seimbang. Label 1 memiliki jumlah data paling banyak, sedangkan label 4 paling sedikit. Kondisi ini penting dicatat karena ketidakseimbangan kelas sering memengaruhi performa model, terutama pada kelas minoritas.

Aspek	Keterangan
Jumlah dokumen	1.000 ulasan
Bahasa	Bahasa Indonesia
Jumlah kelas	5 label sentimen
Distribusi kelas	Tidak seimbang
Sumber	Dataset publik yang digunakan pada notebook proyek

3.2 Tahapan Preprocessing

Tahap	Fungsi	Contoh Dampak
Cleaning	Menghapus simbol, angka, dan karakter tidak relevan	Teks menjadi lebih bersih
Case folding	Mengubah huruf menjadi lowercase	Instagram dan instagram dianggap sama
Tokenization	Memecah teks menjadi kata-kata	Kalimat berubah menjadi daftar token
Stopword removal	Menghapus kata umum yang kurang informatif	Kata seperti 'dan', 'yang' berkurang
Stemming	Mengubah kata ke bentuk dasar	membantu -> bantu

Pada notebook, proses stemming menggunakan Sastrawi memerlukan waktu cukup lama karena dataset berukuran seribu baris. Meski demikian, proses ini penting karena kata dalam Bahasa Indonesia memiliki variasi imbuhan yang cukup banyak. Setelah preprocessing, teks menjadi lebih konsisten dan siap digunakan untuk vectorization.

3.3 Representasi Teks

Dua metode representasi teks yang dibandingkan dalam proyek ini adalah Bag-of-Words dan TF-IDF. Keduanya menghasilkan jumlah kosakata yang sama, yaitu 2.968 kata, tetapi bobot yang diberikan kepada kata di setiap dokumen berbeda. Perbedaan bobot inilah yang

menjadi alasan mengapa hasil akhir model dapat berubah walaupun data masukan terlihat sama.

3.4 Split Data dan Pemodelan

Data dibagi menjadi 80% data latih dan 20% data uji. Pembagian ini cukup umum digunakan untuk menguji kemampuan generalisasi model. Setelah fitur dibentuk, model Logistic Regression dilatih secara terpisah untuk representasi BoW dan TF-IDF. Hasil prediksi kemudian dievaluasi menggunakan akurasi dan classification report.

Langkah	Keluaran
1. Input data mentah	Dataset ulasan Instagram
2. Preprocessing	Teks bersih dan distem
3. Vectorization	Vektor BoW dan TF-IDF
4. Training model	Model Logistic Regression
5. Evaluasi	Akurasi dan laporan klasifikasi

4. Hasil dan Pembahasan

Bagian ini menjelaskan hasil yang diperoleh dari notebook serta analisis terhadap temuan tersebut. Fokus utama pembahasan adalah melihat apakah TF-IDF memberikan keuntungan yang nyata dibanding Bag-of-Words, dan bagaimana kondisi data memengaruhi hasil akhir.

4.1 Distribusi Data

Berdasarkan output notebook, label 1 memiliki jumlah data paling besar, yaitu 481 data. Label 2 berjumlah 156 data, label 5 berjumlah 147 data, label 3 berjumlah 134 data, dan label 4 hanya 82 data. Ketimpangan ini membuat model cenderung lebih mudah mengenali kelas mayoritas dibanding kelas minoritas.

Label	Jumlah Data	Catatan
1	481	Kelas mayoritas
2	156	Jumlah menengah
3	134	Jumlah menengah
4	82	Kelas minoritas
5	147	Jumlah menengah

4.2 Contoh Hasil Preprocessing

Salah satu keunggulan preprocessing adalah membuat teks mentah menjadi lebih rapi dan seragam. Contoh hasil pemrosesan pada notebook memperlihatkan bahwa kata-kata yang tidak penting dapat diubah menjadi representasi yang lebih singkat tetapi tetap mempertahankan makna inti.

Teks Mentah	Teks Setelah Preprocessing
Tolong kembalikan akun saya.. Akun ig saya tiba-tiba ditutup pihak IG	kembali akun akun ig sya tiba tutup pihak ig ...
banyak update banyak juga bug, saya udah follow teman tapi masih error	banyak update banyak bug udah follow teman tapi masih error ...

4.3 Perbandingan Representasi Teks

Hasil ekstraksi fitur menunjukkan bahwa baik BoW maupun TF-IDF menghasilkan ukuran kosakata yang sama, yaitu 2.968 kata. Perbedaan utama ada pada bobot kata. BoW memberi bobot berdasarkan frekuensi, sehingga kata yang sering muncul akan mendominasi. TF-IDF lebih selektif karena kata yang terlalu umum akan diberi bobot lebih rendah. Pada data ulasan, pendekatan ini cukup membantu karena banyak kata umum muncul di hampir semua kelas.

Metode	Jumlah Vocab	Akurasi	Keterangan
Bag-of-Words	2.968	51%	Menangkap frekuensi kata, tetapi kurang peka terhadap kata penting
TF-IDF	2.968	52%	Sedikit lebih baik karena bobot kata lebih informatif

4.4 Analisis Performa Model

Dari hasil eksperimen, perbedaan akurasi antara BoW dan TF-IDF memang kecil, hanya sekitar 1%. Namun, dalam konteks baseline NLP, perbedaan kecil ini tetap bermakna karena menunjukkan bahwa TF-IDF mampu menangkap kata yang lebih relevan dengan sedikit lebih baik. Classification report menunjukkan bahwa kelas 1 memiliki recall tinggi, sedangkan beberapa kelas lain masih sangat rendah bahkan ada yang tidak terprediksi sama sekali.

Hal ini menunjukkan dua hal. Pertama, distribusi data yang tidak seimbang memberi pengaruh besar pada hasil model. Kedua, Logistic Regression dengan fitur dasar masih terbatas dalam memahami nuansa bahasa yang lebih kompleks. Pada teks media sosial, kata-kata slang, typo, dan ekspresi tidak langsung mudah membuat model klasik kesulitan membedakan kelas.

Meskipun begitu, hasil ini tetap berguna sebagai baseline. Model sederhana seperti ini penting karena bisa menjadi pembanding sebelum mencoba pendekatan yang lebih kompleks. Dengan baseline yang jelas, peningkatan performa pada model berikutnya dapat diukur secara lebih objektif.

4.5 Kelebihan dan Keterbatasan

- Kelebihan proyek ini adalah alurnya sederhana, mudah dipahami, dan dapat dijalankan ulang.
- Preprocessing lengkap membantu membersihkan data mentah yang sangat berisik.
- TF-IDF sedikit unggul dibanding BoW pada eksperimen ini.
- Keterbatasan utamanya adalah ketidakseimbangan kelas dan penggunaan model yang masih dasar.

5. Kesimpulan dan Saran

5.1 Kesimpulan

Proyek ini berhasil membangun sistem klasifikasi sentimen sederhana berbasis NLP menggunakan Python. Tahapan preprocessing, vectorization, dan klasifikasi dapat dijalankan dengan baik pada dataset ulasan Instagram berbahasa Indonesia. Hasil eksperimen menunjukkan bahwa TF-IDF memiliki performa sedikit lebih baik dibanding Bag-of-Words, dengan akurasi 52% berbanding 51%.

Kesimpulan penting lainnya adalah preprocessing berperan besar dalam kualitas model. Tanpa pembersihan teks, representasi kata akan dipenuhi noise dan model menjadi lebih sulit belajar. Namun, pada dataset yang tidak seimbang, model dasar masih cenderung bias ke kelas mayoritas.

5.2 Saran

- Gunakan balancing data atau penyesuaian bobot kelas agar kelas minoritas lebih terdeteksi.
- Coba metode representasi lain seperti FastText atau Word2Vec untuk menangkap kemiripan semantik.
- Bandingkan beberapa algoritma klasifikasi, misalnya Naive Bayes, SVM, dan Random Forest.
- Tambahkan visualisasi seperti word cloud, plot frekuensi token, atau PCA embedding agar laporan lebih informatif.

Dengan pengembangan tersebut, performa model kemungkinan bisa meningkat dan hasil analisis menjadi lebih kaya. Dalam pekerjaan NLP, peningkatan kecil pada preprocessing dan representasi data sering memberi dampak yang cukup besar pada performa akhir.

Daftar Pustaka

1. Jurafsky, D., & Martin, J. H. (2023). Speech and Language Processing (3rd ed. draft).
2. Manning, C. D., Raghavan, P., & Schütze, H. (2008). Introduction to Information Retrieval.
3. Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research.
4. Sastrawi. (n.d.). Pustaka stemming dan stopword removal Bahasa Indonesia.
5. Scikit-learn Documentation. (n.d.). CountVectorizer, TfidfVectorizer, LogisticRegression.